

# I. Markov-Ketten mit diskretem Zeitparameter

## 1. Elementare Eigenschaften von Markov-Ketten

Gegeben sei eine Folge von Zufallsvariablen  $(X_n)$  auf dem Wahrscheinlichkeitsraum  $(\Omega, \mathcal{F}, P)$  mit  $X_n : \Omega \rightarrow S$  wobei  $S$  nicht leer, und endlich oder abzählbar unendlich ist.

### Definition

Eine  $S \times S$ -Matrix  $P = (p_{ij})$  heißt *stochastische Matrix*, falls  $p_{ij} \geq 0$  ist und für alle  $i \in S$  die Zeilensumme  $\sum_{j \in S} p_{ij} = 1$  ist.

### Definition

Sei  $P$  eine stochastische Matrix. Eine (endliche oder unendliche) Folge  $X_0, X_1, X_2, \dots$  von  $S$ -wertigen Zufallsvariablen heißt (homogene<sup>1</sup>) *Markov-Kette* mit Übergangsmatrix  $P$ , falls für alle  $n \in \mathbb{N}$ <sup>2</sup> und für alle Zustände  $i_k \in S$  mit

$$P(X_0 = i_0, \dots, X_n = i_n) > 0$$

gilt

$$P(X_{n+1} = i_{n+1} \mid X_0 = i_0, \dots, X_n = i_n) = P(X_{n+1} = i_{n+1} \mid X_n = i_n) := p_{i_n i_{n+1}}.$$

Die  $p_{ij}$  heißen Übergangswahrscheinlichkeiten und die *Startverteilung*  $\nu$  der Kette ist definiert durch  $\nu(i) := P(X_0 = i)$  für  $i \in S$ .

**Bemerkung:** Jede Folge von unabhängigen Zufallsvariablen ist eine Markov-Kette.

### Satz 1.1 (Eigenschaften von Markov-Ketten)

$(X_n)$  ist genau dann eine Markov-Kette mit Übergangsmatrix  $P$ , falls gilt:

$$P(X_k = i_k, 0 \leq k \leq n) = P(X_0 = i_0) \prod_{k=0}^{n-1} p_{i_k i_{k+1}} \quad \forall n \in \mathbb{N}_0 \quad \forall i_k \in S$$

genau dann wenn gilt:

$$P(X_k = i_k, 1 \leq k \leq n \mid X_0 = i_0) = \prod_{k=0}^{n-1} p_{i_k i_{k+1}} \quad \forall n \in \mathbb{N}_0 \quad \forall i_k \in S \text{ mit } P(X_0 = i_0) > 0$$

<sup>1</sup>kurz für zeit-homogen. Die Übergangswahrscheinlichkeiten hängen nicht vom aktuellen Zeitpunkt ab.

<sup>2</sup>Hier ist  $\mathbb{N} = 1, 2, \dots$

genau dann wenn gilt:

$$P(X_k = i_k, m \leq k \leq m+n) = P(X_m = i_m) \prod_{k=m}^{m+n-1} p_{i_k i_{k+1}} \quad \forall m, n \in \mathbb{N}_0 \quad \forall i_k \in S$$

### Beweis

Zur ersten Äquivalenz. Sei  $A_k := [X_k = i_k]$ ,  $k \in \mathbb{N}_0$ .

„ $\Rightarrow$ “ Induktion über  $n$ :  $n = 0$  ✓,  $n \leadsto n+1$ :

$$\begin{aligned} P(A_0 A_1 \dots A_n A_{n+1}) &= P(A_0 \dots A_n) \cdot P(A_{n+1} \mid A_0 \dots A_n) \\ &= P(A_0 \dots A_n) \cdot p_{i_n i_{n+1}} && \text{(Markov-Eigenschaft)} \\ &= P(X_0 = i_0) \prod_{k=0}^n p_{i_k i_{k+1}} && \text{(I.V.)} \end{aligned}$$

„ $\Leftarrow$ “

$$\begin{aligned} P(A_{n+1} \mid A_0 \dots A_n) &= \frac{P(A_0 \dots A_n A_{n+1})}{P(A_0 \dots A_n)} \\ &= p_{i_n i_{n+1}} && \text{(Vor.)} \end{aligned}$$

Die weiteren Äquivalenzen sind ähnlich zu beweisen. ■

**Konstruktion einer Markov-Kette.** Seien  $(Y_n)$  Zufallsvariablen, unabhängig und identisch verteilt (u.i.v.), in  $Z$ . Weiter ist  $g : S \times Z \rightarrow S$  eine messbare Abbildung. Definiere die Folge  $(X_n)$  mit

$$X_0 = c \in S, \quad X_n = g(X_{n-1}, Y_n).$$

Die so konstruierte Folge  $(X_n)$  ist eine Markov-Kette mit Werten in  $S$  und Übergangsmatrix  $P = (p_{ij})$  mit  $p_{ij} = P(g(i, Y_n) = j)$ .

### Beweis

Die Variablen  $X_0, \dots, X_n$  hängen nur von  $X_0, Y_1, \dots, Y_n$  ab, sind also unabhängig von  $Y_{n+1}$ .

$$\begin{aligned} P(X_{n+1} = i_{n+1} \mid X_k = i_k, 0 \leq k \leq n) &= \frac{P(X_k = i_k, 0 \leq k \leq n+1)}{P(X_k = i_k, 0 \leq k \leq n)} \\ &= \frac{P(X_k = i_k, 0 \leq k \leq n, g(i_n, Y_{n+1}) = i_{n+1})}{P(X_k = i_k, 0 \leq k \leq n)} \\ &= \frac{P(X_k = i_k, 0 \leq k \leq n) \cdot P(g(i_n, Y_{n+1}) = i_{n+1})}{P(X_k = i_k, 0 \leq k \leq n)} \\ &= P(g(i_n, Y_{n+1}) = i_{n+1}) \\ &= \frac{P(g(i_n, Y_{n+1}) = i_{n+1}) \cdot P(X_n = i_n)}{P(X_n = i_n)} \\ &= \frac{P(g(i_n, Y_{n+1}) = i_{n+1}, X_n = i_n)}{P(X_n = i_n)} \\ &= P(g(i_n, Y_{n+1}) = i_{n+1} \mid X_n = i_n) \\ &= P(X_{n+1} = i_{n+1} \mid X_n = i_n) \end{aligned} \quad \blacksquare$$

**Bemerkung:** Umgekehrt kann zu jeder stochastischen Matrix  $P$  eine Markov-Kette  $(X_n)$  konstruiert werden mit  $X_n = g(X_{n-1}, Y_n)$ , wobei  $(Y_n)$  u.i.v. und o.B.d.A.  $Y_n \sim U[0, 1]$ .

### Beispiel 1.1 (Lagerhaltung)

Sei  $Y_n$  die Nachfrage nach einem gelagerten Produkt im Zeitintervall  $(n-1, n]$ .  $(Y_n)$  sei u.i.v. und  $Y_n \in \mathbb{N}_0$ . Die Auffüll-Politik sei eine  $(z, Z)$ -Politik mit  $z \leq Z$ ,  $z, Z \in \mathbb{N}$ , die wie folgt funktioniert: Falls der Lagerbestand zur Zeit  $n \leq z$  ist, dann fülle auf  $Z$  auf, sonst tue nichts.

Sei  $X_n$  der Lagerbestand zum Zeitpunkt  $n$ ,  $S = \mathbb{N}_0$ . Es gilt

$$X_n = \begin{cases} (Z - Y_n)^+, & X_{n-1} \leq z \\ (X_{n-1} - Y_n)^+, & X_{n-1} > z \end{cases}$$

Also ist  $(X_n)$  eine Markov-Kette mit Übergangsmatrix  $P = (p_{ij})$  und

$$p_{ij} = \begin{cases} P((Z - Y_n)^+ = j), & i \leq z \\ P((i - Y_n)^+ = j), & i > z \end{cases}$$

### Beispiel 1.2 (Ruinspiel)

Zwei Spieler mit Startkapital  $B \in \mathbb{N}$  Euro spielen in Runden um jeweils einen Euro, etwa mit einem Münzwurf. Spieler I gewinnt dabei mit Wahrscheinlichkeit  $p$ . Sei  $Y_n = 1$ , falls Spieler I die  $n$ -te Runde gewinnt, und  $Y_n = -1$ , falls er die  $n$ -Runde verliert. Wir nehmen an, dass  $Y_n$  u.i.v. ist.


Wir interessieren uns für das Kapital  $X_n$  von Spieler I nach der  $n$ -ten Runde. Damit ist der Zustandsraum  $S = \{0, 1, \dots, 2B\}$ .

Es gilt  $X_0 = B$  und

$$X_n = \begin{cases} 2B, & X_{n-1} = 2B \\ X_{n-1} + Y_n, & 0 < X_{n-1} < 2B \\ 0, & X_{n-1} = 0. \end{cases}$$

Es folgt aus der Konstruktion direkt dass  $(X_n)$  eine Markov-Kette ist mit Übergangsmatrix  $P = (p_{ij})$ , und  $p_{00} = p_{2B, 2B} = 1$  sowie

$$p_{ij} = \begin{cases} p, & j = i + 1 \\ 1 - p, & j = i - 1 \end{cases} \text{ für } 0 < i < 2B.$$



### Beispiel 1.3 (Wartesystem)

Zu jedem Zeitpunkt  $n = 0, 1, \dots$  können maximal  $m$  Kunden bedient werden.  $Y_n$  sei die Anzahl der zufällig im Zeitintervall  $(n-1, n]$  eintreffenden Kunden und sei u.i.v.

Sei  $X_n$  die Anzahl der zur Zeit  $n$  wartenden Kunden,  $S = \mathbb{N}_0$ . Es gilt  $X_0 = c$  und  $X_n = (X_{n-1} - m)^+ + Y_n$ . Also ist  $(X_n)$  eine Markov-Kette mit Übergangsmatrix  $P = (p_{ij})$  und  $p_{ij} = P(Y_n = j - (i - m)^+)$ ,  $i, j \in \mathbb{N}_0$ .

**Definition**

Sei  $P$  eine stochastische  $S \times S$ -Matrix. Dann heißen die Elemente  $p_{ij}^{(n)}$  von  $P^n$  die  $n$ -Schritt-Übergangswahrscheinlichkeiten zu  $P$ . Wir definieren  $P^0 = E$ , also  $p_{ij}^{(0)} = \delta_{ij}$ .

**Satz 1.2**

Sei  $(X_n)$  eine Markov-Kette mit Übergangsmatrix  $P$ . Dann gilt:

- a)  $P(X_{n+m} = j \mid X_m = i) = p_{ij}^{(n)}$  für alle  $i, j \in S, m, n \in \mathbb{N}_0$  mit  $P(X_m = i) > 0$ .
- b)  $P(X_n = j) = \sum_{i \in S} P(X_0 = i) p_{ij}^{(n)}, j \in S, n \in \mathbb{N}$ .

**Beweis**

a)

$$\begin{aligned} P(X_{n+m} = i_{n+m}, X_m = i_m) &= \sum_{i_{m+1}, \dots, i_{n+m-1} \in S} P(X_m = i_m) \prod_{k=m}^{m+n-1} p_{i_k i_{k+1}} \\ &= P(X_m = i_m) p_{i_m i_{m+n}}^{(n)} \end{aligned}$$

b)

$$\begin{aligned} P(X_n = j) &= \sum_{i \in S} P(X_n = j, X_0 = i) \\ &= \sum_{i \in S} P(X_n = j \mid X_0 = i) \cdot P(X_0 = i) \\ &= \sum_{i \in S} P(X_0 = i) p_{ij}^{(n)} \end{aligned} \quad \blacksquare$$

**Bemerkung:** i) Wegen  $P^{n+m} = P^n \cdot P^m$  gilt:

$$p_{ij}^{(n+m)} = \sum_{k \in S} p_{ik}^{(n)} p_{kj}^{(m)} \text{ für } i, j \in S$$

Dies ist die „Chapman-Kolmogorov-Gleichung“.

ii) Ist  $X_0 \sim \nu$ , so gilt  $X_n \sim \nu \cdot P^n$ .

**Satz 1.3 (Existenzsatz für Markov-Ketten)**

Sei  $\nu$  ein Wahrscheinlichkeitsmaß auf  $S$  und  $P$  eine stochastische  $S \times S$ -Matrix. Sei  $X_n$  die  $n$ -te Projektion auf  $\Omega := S^{\mathbb{N}_0}$ , also  $X_n : \Omega \rightarrow S, n \in \mathbb{N}_0$  mit  $X_n(\omega) = X_n((i_0, i_1, \dots)) = i_n$ .

Dann existiert ein Wahrscheinlichkeitsmaß  $P$  auf  $\mathcal{F} = \bigoplus_{n=0}^{\infty} \mathcal{P}(S)$ , sodass  $(X_n)$  eine Markov-Kette mit Übergangsmatrix  $P$  und Startverteilung  $\nu$  ist, d.h:

- $P(X_0 = i_0) = \nu(i_0), i_0 \in S$
- $P(X_{n+1} = j \mid X_n = i) = p_{ij}, i, j \in S, P(X_n = i) > 0$ .

**Beweis**

Satz von Ionescu-Tulcea über die Fortsetzung von Maßen und die Existenz zufälliger Folgen. ■

**2. Klassifikation von Zuständen, Rekurrenz und Transienz**

In diesem Paragraphen widmen wir uns Fragestellungen wie diesen: Welche Zustände in  $S$  werden von der Markov-Kette mit Sicherheit besucht und welche nicht? Wenn sie besucht werden, wie oft?

**Definition**

Sei  $(X_n)$  eine Markov-Kette mit Übergangsmatrix  $P = (p_{ij})$ .

- a)  $i \in S$  führt nach  $j \in S$  (kurz  $i \rightsquigarrow j$ ), falls es ein  $n \in \mathbb{N}$  gibt mit  $p_{ij}^{(n)} > 0$ .
- b)  $i \in S$  kommuniziert mit  $j \in S$  (kurz  $i \leftrightarrow j$ ) falls sowohl  $i \rightsquigarrow j$  als auch  $j \rightsquigarrow i$  gilt.

**Bemerkung:** Für  $i, j \in S$  sei  $i \sim j$  definiert als  $(i \leftrightarrow j) \vee (i = j)$ . Diese Relation ist eine Äquivalenzrelation auf  $S$ , da sie reflexiv, symmetrisch und transitiv ist.

Dies liefert uns eine Partition von  $S$  mit den Äquivalenzklassen  $K(i) := \{j \in S \mid i \sim j\}$ . Die Äquivalenzklasse  $K(i)$  enthält  $i$  selbst und die mit  $i$  kommunizierenden Zustände.


**Definition**

Sei  $(X_n)$  eine Markov-Kette mit Übergangsmatrix  $P = (p_{ij})$ .

- a)  $J \subset S$  heißt *abgeschlossen*, wenn es keine zwei Zustände  $j \in J$  und  $i \in S \setminus J$  gibt mit  $j \rightsquigarrow i$ .
- b) Die Markov-Kette  $(X_n)$  beziehungsweise die Übergangsmatrix  $P$  heißen *irreduzibel*, falls  $S$  nur aus einer Klasse besteht, also für alle  $i, j \in S$ ,  $i \neq j$ , gilt  $i \leftrightarrow j$ .

**Beispiel 2.1**

Skizze, hier ausgelassen

**Beispiel 2.2 (Ruinspiel)****Lemma 2.1**

$J \subset S$  ist genau dann abgeschlossen, wenn  $(p_{ij}, i, j \in J)$  stochastisch ist.

**Beweis**

„ $\Rightarrow$ “: Klar. „ $\Leftarrow$ “: Es gilt:  $(p_{ij}, i, j \in J)$  stochastisch  $\iff (p_{ij}^{(n)}, i, j \in J)$  stochastisch für alle  $n \in \mathbb{N}$ . ■

## I. Markov-Ketten mit diskretem Zeitparameter

Sei  $(X_n)$  eine Markov-Kette mit Übergangsmatrix  $P = (p_{ij})$ . Es sei

$$T_i := \inf\{n \in \mathbb{N} \mid X_n = i\}$$

die (zufällige) Ersteintrittszeit der Markov-Kette in den Zustand  $i$ .

Wir setzen dabei  $\inf \emptyset := \infty$ . Weiter sei für  $i, j \in S$ ,  $n \in \mathbb{N}$ :

$$\begin{aligned} f_{ij}^{(n)} &:= P(T_j = n \mid X_0 = i) = P_i(T_j = n) \\ &= P(X_n = j, X_\nu \neq j \text{ für } 1 \leq \nu < n \mid X_0 = i) \\ f_{ij}^{(0)} &:= 0 \end{aligned}$$

Offenbar ist  $f_{ij}^{(1)} = p_{ij}$ . Weiter definieren wir

$$f_{ij}^* := \sum_{n=0}^{\infty} f_{ij}^{(n)} = \sum_{n=0}^{\infty} P_i(T_j = n) = P_i(T_j < \infty) = P_i(\exists n \in \mathbb{N} : X_n = j) \in [0, 1]$$

### Definition

Ein Zustand  $i \in S$  heißt *rekurrent*, falls  $f_{ii}^* = 1$  und *transient* sonst.

#### Lemma 2.2

Für alle  $n \in \mathbb{N}$ ,  $i, j \in S$  gilt:

$$p_{ij}^{(n)} = \sum_{k=1}^n f_{ij}^{(k)} p_{jj}^{(n-k)}$$

### Beweis (Methode des ersten Besuches)

Unter Verwendung der Formel  $P(AB \mid C) = P(B \mid C) \cdot P(A \mid BC)$  für Ereignisse  $A, B, C$  zeigen wir:

$$\begin{aligned} p_{ij}^{(n)} &= P_i(X_n = j) = \sum_{k=1}^n P(X_n = j, X_\mu \neq j, 1 \leq \mu < k, X_k = j \mid X_0 = i) \\ &= \sum_{k=1}^n P_i(X_\mu \neq j, 1 \leq \mu < k, X_k = j) \cdot \\ &\quad \underbrace{P(X_n = j \mid X_0 = i, X_\mu \neq j, 1 \leq \mu < k, X_k = j)}_{=P(X_n=j \mid X_k=j)} \\ &= \sum_{k=1}^n f_{ij}^{(k)} p_{jj}^{(n-k)} \end{aligned} \quad \blacksquare$$

### Satz 2.3

$i \in S$  ist rekurrent genau dann, wenn gilt:

$$\sum_{n=0}^{\infty} p_{ii}^{(n)} = \infty$$

**Beweis**

Für  $s \in (0, 1)$  erhalten wir aus Lemma 2.2:

$$\begin{aligned} \sum_{n=0}^{\infty} p_{ii}^{(n)} s^n &= 1 + \sum_{n=1}^{\infty} p_{ii}^{(n)} s^n = \\ &= 1 + \sum_{n=1}^{\infty} s^n \sum_{k=1}^n f_{ii}^{(k)} p_{ii}^{(n-k)} \\ &= 1 + \sum_{k=1}^{\infty} f_{ii}^{(k)} s^k \sum_{n=k}^{\infty} p_{ii}^{(n-k)} s^{n-k} \\ &= 1 + \sum_{k=1}^{\infty} f_{ii}^{(k)} s^k \sum_{n=0}^{\infty} p_{ii}^{(n)} s^n \end{aligned}$$

Abkürzend schreiben wir  $F(s) := \sum_{k=1}^{\infty} f_{ii}^{(k)} s^k$  und  $P(s) = \sum_{n=0}^{\infty} p_{ii}^{(n)} s^n$ , also gilt

$$P(s) = 1 + F(s) \cdot P(s).$$

Nun sei  $s \rightarrow 1$  (monotone Konvergenz!), und wir erhalten

$$P(1) = 1 + f_{ii}^* \cdot P(1).$$

Es folgt: Ist  $f_{ii}^* = 1$ , so gilt  $P(1) = 1 + P(1)$ , also ist  $P(1) = \sum_{n=0}^{\infty} p_{ii}^{(n)} = \infty$ . Ist ansonsten  $f_{ii}^* < 1$ , so gilt  $P(1) = \frac{1}{1-f_{ii}^*} < \infty$ . ■

**Bemerkung:** Die im Satz 2.3 auftretende Reihe kann wie folgt interpretiert werden:

$$\sum_{n=0}^{\infty} p_{ii}^{(n)} = \sum_{n=0}^{\infty} E_i[1_{[X_n=i]}] = E_i\left(\sum_{n=0}^{\infty} 1_{[X_n=i]}\right)$$

Sie bezeichnet also die erwartete Anzahl der Besuche des Zustandes  $i \in S$ .

**Satz 2.4 (Solidaritätsprinzip)**

Ist ein Zustand  $i \in S$  rekurrent (bzw. transient), so ist jeder Zustand in  $K(i)$  rekurrent (bzw. transient).

**Beweis**

Sei  $i$  rekurrent und  $j \in K(i)$ ,  $j \neq i$ , das heißt es gibt  $n, m \in \mathbb{N}$ , sodass  $p_{ij}^{(m)} \cdot p_{ji}^{(n)} > 0$ . Mit der Abschätzung

$$\sum_{k=0}^{\infty} p_{jj}^{(k)} \geq \sum_{k=0}^{\infty} p_{jj}^{(m+n+k)} \geq \sum_{k=0}^{\infty} p_{ji}^{(n)} p_{ii}^{(k)} p_{ij}^{(m)} = p_{ij}^{(m)} p_{ji}^{(n)} \sum_{k=0}^{\infty} p_{ii}^{(k)}$$

und Satz 2.3 ist  $\sum_{k=0}^{\infty} p_{jj}^{(k)} = \infty$  und  $j$  rekurrent. ■

**Bemerkung:** Ist  $i \in S$  rekurrent (bzw. transient), so sagen wir  $K(i)$  ist rekurrent (bzw. transient).


Ist  $(X_n)$  irreduzibel und ein  $i \in S$  ist rekurrent (bzw. transient), so sagen wir  $(X_n)$  ist rekurrent (bzw. transient).

**Beispiel 2.3 (Irrfahrt auf den ganzen Zahlen, „Random Walk“)**

Es sei  $X_n = \sum_{k=1}^n Y_k = X_{n-1} + Y_n$  und  $X_0 = 0$ , wobei  $(Y_n)$  u.i.v. mit

$$P(Y_n = 1) = p = 1 - P(Y_n = -1) = 1 - q, \quad p \in (0, 1)$$

ist  $(S = \mathbb{Z})$ .



$(X_n)$  ist nach Konstruktion eine irreduzible Markov-Kette. Ist  $(X_n)$  rekurrent oder transient?

Wir wenden Satz 2.3 an und untersuchen o.B.d.A.  $i = 0$ . Es gilt für alle  $n \in \mathbb{N}_0$ :

$$p_{00}^{(2n+1)} = 0$$

$$p_{00}^{(2n)} = p^n q^n \binom{2n}{n} = p^n q^n \frac{(2n)!}{(n!)^2}$$

Mit der Stirling-Formel ( $n! \simeq (\frac{n}{e})^n \cdot \sqrt{2\pi n}$ ) erhält man dann

$$p_{00}^{(2n)} \approx (pq)^n \cdot \frac{(\frac{2n}{e})^{2n} \sqrt{4\pi n}}{(\frac{n}{e})^{2n} 2\pi n} = \frac{(4pq)^n}{\sqrt{\pi n}}.$$

**Fall 1** Ist  $p = q = \frac{1}{2}$ , so ist  $p_{00}^{(2n)} \approx \frac{1}{\sqrt{\pi n}}$ , also ist  $\sum_{n=0}^{\infty} p_{00}^{(2n)} = \infty$  und die Markov-Kette ist rekurrent.

**Fall 2** Ist dagegen  $p \neq q$ , also  $pq < \frac{1}{4}$ , so ist  $\sum_{n=0}^{\infty} p_{00}^{(2n)} \leq c \cdot \sum_{n=0}^{\infty} (4pq)^n < \infty$ , also ist die Markov-Kette transient.

**Bemerkung:** Betrachtet man die symmetrische Irrfahrt auf  $\mathbb{Z}^d$ , also  $p_{ij} = \frac{1}{2d}$  für  $\|i - j\| = 1$ , mit  $\|\cdot\|$  der  $l^1$ -Norm und  $i, j \in \mathbb{Z}^d$ , so ist die Irrfahrt rekurrent für  $d = 1, 2$  und transient sonst.

**Lemma 2.5**

Liegen  $i$  und  $j$  in der selben rekurrenten Klasse, so gilt  $f_{ij}^* = f_{ji}^* = 1$ .

**Lemma 2.6**

Für alle  $i, j \in S$  gilt: Wenn  $j$  transient ist, dann gilt

$$\sum_{n=0}^{\infty} p_{ij}^{(n)} < \infty$$

Insbesondere ist

$$\lim_{n \rightarrow \infty} p_{ij}^{(n)} = 0.$$



**Beweis**

Summiere die Gleichung in Lemma 2.2 über alle  $n$ :

$$\begin{aligned}
 \sum_{n=0}^{\infty} p_{ij}^{(n)} &= \delta_{ij} + \sum_{n=1}^{\infty} \sum_{k=1}^n f_{ij}^{(k)} p_{jj}^{(n-k)} \\
 &= \delta_{ij} + \sum_{k=1}^{\infty} f_{ij}^{(k)} \sum_{n=k}^{\infty} p_{jj}^{(n-k)} \\
 &= \delta_{ij} + f_{ij}^* \underbrace{\sum_{n=0}^{\infty} p_{jj}^{(n)}}_{< \infty \text{ da } j \text{ transient}} < \infty
 \end{aligned}
 \quad \blacksquare$$

**Satz 2.7**

Ist eine Klasse  $K \subseteq S$  rekurrent, so ist  $K$  abgeschlossen bzw.  $(p_{ij}, i, j \in K)$  ist stochastisch.

**Beweis**

Wir zeigen: Ist  $i \in K$  rekurrent und  $i \rightsquigarrow j$ ,  $i \neq j$ , dann gilt  $j \rightsquigarrow i$  und damit  $j \in K$ .

Angenommen,  $j \rightsquigarrow i$  gelte nicht, also  $p_{ji}^{(n)} = 0$  für alle  $n \in \mathbb{N}$ , und sei  $N \in \mathbb{N}$  die kleinste Zahl mit  $p_{ij}^{(N)} > 0$ . Es gilt nun für alle  $n \in \mathbb{N}$

$$P_i(X_N = j, X_n = i) = 0.$$

Denn für  $n > N$  gilt:  $P_i(X_N = j, X_n = i) = p_{ij}^{(N)} p_{ji}^{(n-N)} = 0$  und für  $n < N$  gilt:  $P_i(X_N = j, X_n = i) = p_{ii}^{(n)} p_{ij}^{(N-n)} = 0$ , da  $N - n < N$ .

Also ist  $P_i(T_i \leq m, X_N = j) = \sum_{n=1}^m P_i(T_i = n, X_N = j) \leq \sum_{n=1}^m P_i(X_n = i, X_N = j) = 0$  und damit

$$\begin{aligned}
 \sum_{n=1}^m f_{ii}^{(n)} &= P_i(T_i \leq m) \\
 &= P_i(T_i \leq m, X_N \neq j) \\
 &\leq P_i(X_N \neq j) \\
 &= 1 - P_i(X_N = j) = 1 - p_{ij}^{(N)}.
 \end{aligned}$$

Für  $m \rightarrow \infty$  folgt dann

$$1 = f_{ii}^* = \sum_{n=1}^{\infty} f_{ii}^{(n)} \leq 1 - p_{ij}^{(N)} < 1,$$

was ein Widerspruch ist. ■

**Satz 2.8**

Ist die Klasse  $K$  endlich und abgeschlossen, so ist  $K$  rekurrent.

### Beweis

Da  $(p_{ij}, i, j \in K)$  stochastisch ist, folgt induktiv, dass  $(p_{ij}^{(n)}, i, j \in K)$  stochastisch für alle  $n \in \mathbb{N}$  ist. Angenommen,  $K$  wäre transient. Sei dann  $j \in K$ , dann ist nach Lemma 2.6  $p_{ij}^{(n)} \rightarrow 0$  für  $n \rightarrow \infty$  und alle  $i \in S$ . Für  $i \in K$  folgt also:  $1 = \sum_{j \in K} p_{ij}^{(n)} \rightarrow 0$  für  $n \rightarrow \infty$ . Widerspruch. ■

**Bemerkung:** Insbesondere gilt: Ist  $S$  endlich und  $P$  irreduzibel, so ist die Markov-Kette rekurrent.

### Beispiel 2.4 (Irrfahrt mit reflektierenden Grenzen)

Die Irrfahrt ist irreduzibel und rekurrent nach Satz 2.8.

## Absorbtionswahrscheinlichkeiten

Sei  $(X_n)_{n \in \mathbb{N}}$  eine Markov-Kette mit Zustandsraum  $S$  und Übergangsmatrix  $P = (p_{ij})$ . Aufgrund der bisherigen Ergebnisse können wir  $S$  zerlegen in rekurrente Klassen  $K_1, K_2, \dots$  und eine Menge von transienten Zuständen  $T$ , also  $S = T \cup K_1 \cup K_2 \cup \dots$ .

Es sei  $\tau := \inf\{n \geq 0 \mid X_n \notin T\}$  die Austrittszeit aus der Menge der transienten Zustände. Für  $i \in T$ ,  $k \in T^c$  interessiert uns  $u_{ik} = P_i(X_\tau = k)$ , vorausgesetzt  $P_i(\tau < \infty) = 1$ .

Wir unterteilen  $P = (p_{ij})$  in

$$P = \begin{pmatrix} Q & R \\ 0 & \tilde{P} \end{pmatrix}$$

wobei  $Q$  die Einschränkung von  $P$  auf die transienten Zustände ist, also  $Q = (q_{ij}) = (p_{ij}, i, j \in T)$ .

### Satz 2.9

Für  $i \in T$ ,  $j \in T^c$  gilt:

$$u_{ij} = \sum_{k \in T} q_{ik} u_{kj} + p_{ij}.$$

**Beweis**

Sei  $i \in T$ ,  $j \in T^c$ .

$$\begin{aligned}
u_{ij} &= P_i(X_\tau = j) \\
&= \sum_{k \in S} P_i(X_\tau = j, X_1 = k) \\
&= \underbrace{\sum_{k \in T} P_i(X_\tau = j, X_1 = k)}_{=: A} + \underbrace{\sum_{k \in T^c} P_i(X_\tau = j, X_1 = k)}_{=: p_{ij}} \\
A &= \sum_{k \in T} \sum_{n \geq 2} P_i(\tau = n, X_n = j, X_1 = k) \\
&= \sum_{k \in T} \sum_{n \geq 2} P_i(X_2 \in T, \dots, X_{n-1} \in T, X_n = j, X_1 = k) \\
&= \sum_{k \in T} \sum_{n \geq 2} P_i(X_2 \in T, \dots, X_{n-1} \in T, X_n = j \mid X_1 = k) \cdot P_i(X_1 = k) \\
&= \sum_{k \in T} \sum_{n \geq 2} p_{ik} P_k(X_1 \in T, \dots, X_{n-2} \in T, X_{n-1} = j) \\
&= \sum_{k \in T} \sum_{n \geq 2} p_{ik} P_k(\tau = n - 1, X_\tau = j) \\
&= \sum_{k \in T} p_{ik} P_k(X_\tau = j) \\
&= \sum_{k \in T} p_{ik} u_{kj}
\end{aligned}$$

Da für  $i, k \in T$  gilt:  $p_{ik} = q_{ik}$ , folgt die Behauptung. ■

**Bemerkung:** Es sei  $U = (u_{ij})_{i \in T, j \in T^c}$ . Dann lässt sich Satz 2.9 schreiben als  $U = QU + R$  bzw.  $U - QU = R$ , also  $(I - Q)U = R$ . Falls  $I - Q$  invertierbar ist, ist  $U = (I - Q)^{-1}R$

### 3. Stationäre Verteilungen

Sei  $(X_n)$  eine Markov-Kette mit Übergangsmatrix  $P$  und Startverteilung  $\nu$ .

Dann ist  $X_n \sim \nu \cdot P^n$ . Im Allgemeinen hängt diese Verteilung von  $n$  ab. Es gibt aber spezielle Verteilungen  $\nu$ , sodass die mit dieser Verteilung gestartete Kette zu jedem Zeitpunkt  $n$  die selbe Verteilung  $\nu$  besitzt. Man sagt dann, die Kette ist *im Gleichgewicht* bzw. *stationär*.

**Definition**

Eine Abbildung  $\nu : S \rightarrow \mathbb{R}_{\geq 0}$  heißt *Maß*.

NB: Ein Maß  $\nu$  definiert ein Maß  $\mathcal{P}(S) \rightarrow \mathbb{R}_{\geq 0}$ ,  $A \mapsto \sum_{a \in A} \nu(a)$  im gewöhnlichen Sinne. Falls  $\sum_{a \in S} \nu(a) = 1$ , so definiert es sogar eine Verteilung.

**Definition**

Sei  $(X_n)$  eine Markov-Kette mit Übergangsmatrix  $P = (p_{ij})$ . Ein Maß  $\nu$  heißt *invariant* für  $P$ , falls  $\nu \cdot P = \nu$ , d.h. falls gilt:

$$\sum_{i \in S} \nu(i) \cdot p_{ij} = \nu(j).$$

## I. Markov-Ketten mit diskretem Zeitparameter

Ist  $\nu$  eine Verteilung und invariant, so nennt man  $\nu$  auch *stationäre Verteilung* oder *Gleichgewichtsverteilung*.

**Bemerkung:** a) Ist  $S$  endlich, so kann jedes (nichtdegenerierte) invariante Maß zu einer stationären Verteilung normiert werden.

b) Ist  $\nu$  invariant, so gilt  $\nu \cdot P^n = \nu$  ( $n \in \mathbb{N}_0$ ).

Ist  $\nu$  eine stationäre Verteilung, so gilt

$$P_\nu(X_n = j) = \sum_{i \in S} \nu(i) \cdot p_{ij}^{(n)} = \nu(j),$$

d.h. die mit  $\nu$  gestartete Kette hat zu jedem Zeitpunkt die Verteilung  $\nu$ .

c) Ist  $P$  irreduzibel und  $\nu \neq 0$  ein invariantes Maß, so ist  $\nu(j) > 0$  für jedes  $j \in S$ .

Denn:  $\nu \neq 0$ , also existiert  $i_0 \in S$  mit  $\nu(i_0) > 0$ . Wegen der Irreduzibilität gibt es ferner für jedes  $j \in S$  ein  $n \in \mathbb{N}_0$  mit  $p_{i_0 j}^{(n)} > 0$ . Zusammen:

$$\nu(j) = \sum_{i \in S} \nu(i) \cdot p_{ij}^{(n)} \geq \nu(i_0) p_{i_0 j}^{(n)} > 0$$

Gibt es immer ein invariantes Maß bzw. eine stationäre Verteilung? Ist es eindeutig?

Im Folgenden sei  $P$  irreduzibel. Wir definieren für ein beliebiges  $k \in S$  das Maß  $\gamma_k$  wie folgt:

$$\gamma_k(i) := E_k \left[ \sum_{n=1}^{T_k} 1_{[X_n=i]} \right]$$

### Satz 3.1

Sei  $(X_n)$  irreduzibel und rekurrent,  $k \in S$ . Dann gilt:

- a)  $\gamma_k$  ist ein invariantes Maß
- b)  $0 < \gamma_k < \infty$
- c)  $\gamma_k$  ist das einzige invariante Maß mit  $\gamma_k(k) = 1$  (d.h.  $\gamma_k$  ist eindeutig bis auf Vielfache).

### Beweis

a) Zunächst gilt:

$$\begin{aligned} \gamma_k(i) &= E_k \left[ \sum_{n=1}^{T_k} 1_{[X_n=i]} \right] = E_k \left[ \sum_{n=1}^{\infty} 1_{[X_n=i, n \leq T_k]} \right] = \sum_{n=1}^{\infty} P_k(X_n = i, n \leq T_k) \\ &= \sum_{n=1}^{\infty} \sum_{j \in S, j \neq k} P_k(X_n = i, X_{n-1} = j, n \leq T_k) \end{aligned}$$

Für  $j \neq k$  erhält man

$$\begin{aligned}
 & P_k(X_n = i, X_{n-1} = j, n \leq T_k) \\
 &= P(X_n = i, X_{n-1} = j, X_{n-2} \neq k, \dots, X_1 \neq k, X_0 = k) / P(X_0 = k) \\
 &= P(X_n = i \mid X_{n-1} = j, X_{n-2} \neq k, \dots, X_1 \neq k, X_0 = k) \cdot P_k(X_{n-1} = j, X_{n-2} \neq k, \dots, X_1 \neq k) \\
 &= p_{ji} \cdot P_k(X_{n-1} = j, n \leq T_k)
 \end{aligned}$$

Die so erhaltene Identität gilt auch für  $j = k$  und es folgt

$$\begin{aligned}
 \gamma_k(i) &= \sum_{n=1}^{\infty} \sum_{j \in S} P_k(X_n = i, X_{n-1} = j, n \leq T_k) \\
 &= \sum_{n=1}^{\infty} \sum_{j \in S} p_{ji} \cdot P_k(X_{n-1} = j, n \leq T_k) \\
 &= \sum_{j \in S} p_{ji} \sum_{n=0}^{\infty} P_k(X_n = j, n+1 \leq T_k) \\
 &= \sum_{j \in S} p_{ji} E_k \left[ \sum_{n=0}^{T_k-1} 1_{[X_n=j]} \right] \\
 &= \sum_{j \in S} p_{ji} E_k \left[ \sum_{n=1}^{T_k} 1_{[X_n=j]} \right] = \sum_{j \in S} \gamma_k(j) p_{ji}
 \end{aligned}$$

b) Nach Bemerkung c) oben gilt  $\gamma_k > 0$ , denn  $\gamma_k(k) = 1$ . Wegen  $\gamma_k = \gamma_k \cdot P^n$  folgt

$$1 = \gamma_k(k) \geq \gamma_k(j) \cdot p_{jk}^{(n)}$$

für jedes  $j \in S$ . Es gibt allerdings mindestens ein  $p_{jk}^{(n)} > 0$ , denn die Markov-Kette ist irreduzibel; daran erkennt man  $\gamma_k < \infty$ .

c) Sei  $\lambda$  ein weiteres, invariantes Maß mit  $\lambda(k) = 1$ . Es gilt also:

$$\begin{aligned}
 \lambda(j) &= \sum_{i \in S \setminus \{k\}} \lambda(i) \cdot p_{ij} + 1 \cdot p_{kj} \\
 &= \sum_{i \in S \setminus \{k\}} \left( \sum_{l \in S \setminus \{k\}} \lambda(l) \cdot p_{li} + p_{ki} \right) p_{ij} + p_{kj} \\
 &= \sum_{i, l \in S \setminus \{k\}} \lambda(l) \cdot p_{li} \cdot p_{ij} + \sum_{i \in S \setminus \{k\}} p_{ki} \cdot p_{ij} + p_{kj} \\
 &= \sum_{i, l \in S \setminus \{k\}} \lambda(l) \cdot p_{li} \cdot p_{ij} + P_k(X_2 = j, T_k \geq 2) + P_k(X_1 = j, T_k \geq 1)
 \end{aligned}$$

Iterativ erhalten wir für  $n \in \mathbb{N}$ :

$$\begin{aligned}
 \lambda(j) &= \sum_{i_0, i_1, \dots, i_n \in S \setminus \{k\}} \lambda(i_n) \prod_{r=1}^n p_{i_r i_{r-1}} p_{i_0 j} + \sum_{r=1}^{n+1} P_k(X_r = j, T_k \geq r) \\
 &\geq \sum_{r=1}^{n+1} P_k(X_r = j, T_k \geq r) = E_k \left[ \sum_{r=1}^{\min(n+1, T_k)} 1_{[X_r=j]} \right] \xrightarrow{n \rightarrow \infty} \gamma_k(j).
 \end{aligned}$$

Es ist also  $\lambda - \gamma_k$  ebenfalls ein invariantes Maß mit  $(\lambda - \gamma_k)(k) = 0$ ; nach Bemerkung c) folgt  $\lambda - \gamma_k = 0$ , d.h.  $\lambda = \gamma_k$ . ■

**Bemerkung:** a) Ist  $S$  endlich und  $P$  irreduzibel, so folgt aus Satz 3.1, dass eine stationäre Verteilung existiert.

b) Ist  $(X_n)$  irreduzibel und transient, so kann keine stationäre Verteilung existieren, denn:

Angenommen es existiert eine stationäre Verteilung  $\pi$ . Dann ist

$$\pi(j) = \sum_{i \in S} \pi(i) p_{ij}^{(n)}.$$

Für  $n \rightarrow \infty$  wird daraus (mit majorisierter Konvergenz und der bekannten Eigenschaft transienter Übergangswahrscheinlichkeiten):

$$\begin{aligned} \pi(j) &= \sum_{i \in S} \pi(i) \lim_{n \rightarrow \infty} p_{ij}^{(n)} \\ &= \sum_{i \in S} \pi(i) \cdot 0 \\ &= 0 \end{aligned}$$

### Definition

Für  $i \in S$  sei

$$\begin{aligned} m_i &:= E_i[T_i] = \sum_{n=1}^{\infty} n \cdot P_i(T_i = n) + \infty \cdot (1 - f_{ii}^*) \\ &= \sum_{n=1}^{\infty} n \cdot f_{ii}^{(n)} + \infty \cdot (1 - f_{ii}^*) \end{aligned}$$

die *mittlere Rückkehrzeit* des Zustands  $i$ .

**Bemerkung:** Ist  $j$  transient, so folgt  $m_j = \infty$ .

### Definition

Ein Zustand  $i \in S$  heißt *positiv rekurrent*, falls  $m_i < \infty$  und *nullrekurrent*, falls  $i$  rekurrent und  $m_i = \infty$  ist.

**Bemerkung:** Jeder positiv rekurrente Zustand ist auch rekurrent.

### Satz 3.2

Sei  $(X_n)$  eine irreduzible Markov-Kette. Die folgenden Aussagen sind äquivalent:

- i) Es existiert eine stationäre Verteilung.
- ii) Es gibt einen positiv rekurrenten Zustand  $i \in S$ .
- iii) Alle Zustände in  $S$  sind positiv rekurrent.

Sind diese Bedingungen erfüllt, so ist die stationäre Verteilung eindeutig und durch

$$\pi(i) = \frac{1}{m_i}$$

gegeben.

**Beweis**(iii)  $\implies$  (ii)  $\checkmark$ (ii)  $\implies$  (i) Sei  $k \in S$  mit  $m_k < \infty$ , dann ist  $(X_n)$  rekurrent und mit Satz 3.1 ist  $\gamma_k$  ein invariantes Maß. Dann gilt:

$$\begin{aligned}
\sum_{j \in S} \gamma_k(j) &= \sum_{j \in S} E_k \left[ \sum_{n=1}^{T_k} 1_{[X_n=j]} \right] \\
&= E_k \left[ \sum_{n=1}^{T_k} \sum_{j \in S} 1_{[X_n=j]} \right] \\
&= E_k \left[ \sum_{n=1}^{T_k} 1 \right] \\
&= E_k[T_k] = m_k < \infty
\end{aligned}$$

also ist  $\gamma_k$  normierbar.(i)  $\implies$  (iii) Sei  $\pi$  eine stationäre Verteilung und  $k \in S$ . Insbesondere sind  $\pi(j) > 0$  für alle  $j \in S$ . Dann ist  $\gamma := \frac{\pi}{\pi(k)}$  ein invariantes Maß mit  $\gamma(k) = 1$ . Nach Satz 3.1 c) folgt  $\gamma = \gamma_k$ . Beachte dass im Beweis von 3.1 c) die Voraussetzung  $(X_n)$  rekurrent nicht verwendet wurde. Wie oben ist

$$m_k = \sum_{j \in S} \gamma_k(j) = \frac{1}{\pi(k)} \sum_{j \in S} \pi(j) = \frac{1}{\pi(k)} < \infty.$$

Da  $k \in S$  beliebig ist, folgt die Behauptung (iii).Außerdem ist gezeigt, dass  $\pi(k) = \frac{1}{m_k}$ . ■**Bemerkung:** i) Es gilt also die folgende Trichotomie für irreduzible Markov-Ketten, das heißt eine irreduzible Markov-Kette gehört immer zu genau einem der folgenden Fälle:

- Die Markov-Kette ist transient, es gibt keine stationäre Verteilung.
- Die Markov-Kette ist nullrekurrent, insbesondere gilt für alle  $i, j \in S$ :

$$P_i(T_j < \infty) = 1 \text{ und } E_i[T_j] = \infty$$

und es gibt ein (bis auf Vielfache) eindeutiges invariantes Maß, aber keine stationäre Verteilung.

- Die Markov-Kette ist positiv rekurrent, für alle  $i, j \in S$  ist  $E_i[T_j] < \infty$  und es gibt eine stationäre Verteilung.

ii) Ist  $S$  endlich und die Markov-Kette irreduzibel, so ist sie automatisch positiv rekurrent.iii) Ist  $\pi$  eine stationäre Verteilung, so gilt:

$$\pi(i) = \frac{\gamma_k(i)}{\sum_{j \in S} \gamma_k(j)} = \frac{E_k[\sum_{n=1}^{T_k} 1_{[X_n=i]}]}{E_k[T_k]}.$$

 $\pi(i)$  ist also der durchschnittliche Bruchteil der Zeit, den die Markov-Kette im Zustand  $i$  verbringt, während sie einen Zyklus durchläuft.

### Beispiel 3.1

Sei  $S = \{1, 2\}$ . Die Übergangsmatrix  $P$  sei gegeben durch

$$P = \begin{pmatrix} 1-\alpha & \alpha \\ \beta & 1-\beta \end{pmatrix}, \quad \alpha, \beta \in (0, 1].$$

Also ist die Markov-Kette irreduzibel und positiv rekurrent. Die stationäre Verteilung ist die Lösung des linearen Gleichungssystems

$$\pi P = \pi$$

unter Berücksichtigung von  $\pi \geq 0$  und  $\pi(1) + \pi(2) = 1$ , also

$$\pi(1) = \frac{\beta}{\alpha + \beta}, \quad \pi(2) = \frac{\alpha}{\alpha + \beta}.$$

### Beispiel 3.2 (Irrfahrt)

Siehe Beispiel 2.3: Für  $p \neq q$  ist die Markov-Kette transient. Existiert ein invariantes Maß? Ansatz:

$$\begin{aligned} \gamma(j) &= \sum_{i \in \mathbb{Z}} \gamma(i) p_{ij} = \gamma(j+1) \cdot q + \gamma(j-1) \cdot p \\ \implies \gamma(j+1) - \gamma(j) &= \frac{p}{q} (\gamma(j) - \gamma(j-1)) \end{aligned}$$

Also:  $\gamma_1(j) = 1$  und  $\gamma_2(j) = (\frac{p}{q})^j$ ,  $j \in \mathbb{Z}$ , sind verschiedene invariante Maße.

Ist  $p = q = \frac{1}{2}$ , so ist die Markov-Kette rekurrent. Ist sie nullrekurrent oder positiv rekurrent? Es gibt keine stationäre Verteilung (siehe oben), die Markov-Kette ist also nullrekurrent.

### Beispiel 3.3 (Geburts- und Todesprozess in diskreter Zeit)

Es sei  $(X_n)$  eine Markov-Kette mit  $S = \mathbb{N}_0$  und Übergangsmatrix

$$P = \begin{pmatrix} p_{00} & p_{01} & 0 & \cdots & \\ p_{10} & p_{11} & p_{12} & 0 & \cdots \\ 0 & p_{21} & p_{22} & p_{23} & \ddots \\ \vdots & 0 & p_{32} & p_{33} & \ddots \\ & \vdots & \ddots & \ddots & \ddots \end{pmatrix}$$

mit  $p_{01} > 0$ ,  $p_{i,i+1} > 0$ ,  $p_{i,i-1} > 0$  für alle  $i \geq 1$ , also ist  $(X_n)$  irreduzibel. Wann ist  $(X_n)$  positiv rekurrent?

Der Ansatz  $\pi P = \pi$  liefert:

$$\begin{aligned} \pi(0) &= p_{00} \cdot \pi(0) + p_{10} \cdot \pi(1) \\ \pi(i) &= p_{i-1,i} \cdot \pi(i-1) + p_{ii} \cdot \pi(i) + p_{i+1,i} \cdot \pi(i+1) \\ \iff p_{i,i-1} \cdot \pi(i) + p_{i,i+1} \pi(i) &= p_{i-1,i} \cdot \pi(i-1) + p_{i+1,i} \cdot \pi(i+1) \\ \iff p_{i+1,i} \cdot \pi(i+1) - p_{i,i+1} \cdot \pi(i) &= p_{i,i-1} \cdot \pi(i) - p_{i-1,i} \cdot \pi(i-1) \\ &= \dots = p_{10} \cdot \pi(1) - p_{01} \cdot \pi(0) \end{aligned}$$



Aus der ersten Gleichung folgt  $p_{01} \cdot \pi(0) = p_{10} \cdot \pi(1)$  und damit:

$$\begin{aligned} p_{i+1,i} \cdot \pi(i+1) - p_{i,i+1} \cdot \pi(i) &= 0 \\ \implies \pi(i+1) &= \frac{p_{i,i+1}}{p_{i+1,i}} \pi(i) \\ &= \dots = \pi(0) \cdot \prod_{k=0}^i \frac{p_{k,k+1}}{p_{k+1,k}}. \end{aligned}$$

Für  $\pi(0) > 0$  erhält man ein invariantes Maß.  $(X_n)$  ist positiv rekurrent, falls

$$\sum_{i=1}^{\infty} \prod_{k=0}^i \frac{p_{k,k+1}}{p_{k+1,k}} < \infty.$$

Im Spezialfall  $p_{k,k+1} = p$ ,  $p_{k,k-1} = q = 1 - p$ ,  $k \geq 1$  und  $p_{01} = p$ ,  $p_{00} = 1 - p$  gilt

$$(X_n) \text{ ist positiv rekurrent} \iff \sum_{i=1}^{\infty} \left(\frac{p}{q}\right)^{i+1} < \infty \iff p < q.$$

## 4. Konvergenz gegen die stationäre Verteilung

Sei  $(X_n)$  eine Markov-Kette mit Übergangsmatrix  $P$ . Wir nehmen an, dass  $(X_n)$  bzw.  $P$  aperiodisch ist, das heißt: Für alle Zustände  $i \in S$  gilt:

$$d_i := \text{ggT}\{n \in \mathbb{N} \mid p_{ii}^{(n)} > 0\} = 1$$

### Lemma 4.1

$P$  ist genau dann irreduzibel und aperiodisch, wenn für alle  $i, j \in S$  eine Zahl  $n_0 \in \mathbb{N}$  existiert, sodass für alle  $n \geq n_0$  gilt:  $p_{ij}^{(n)} > 0$ .

(ohne Beweis)

### Satz 4.2 (Konvergenzsatz)

Es sei  $(X_n)$  irreduzibel, aperiodisch und positiv rekurrent mit stationärer Verteilung  $\pi$ . Dann gilt für alle  $i, j \in S$ :

$$\lim_{n \rightarrow \infty} p_{ij}^{(n)} = \pi(j) = \frac{1}{m_j}$$

### Beweis

Wir benutzen ein sogenanntes ‘‘Kopplungsargument’’.

## I. Markov-Ketten mit diskretem Zeitparameter

(1) Sei  $(Y_n)$  eine weitere Markov-Kette, unabhängig von  $(X_n)$  mit gleicher Übergangsmatrix und Startverteilung  $\pi$ , also  $Y_n \sim \pi$  für alle  $n \in \mathbb{N}$ . Es sei

$$T := \inf\{n \in \mathbb{N} \mid X_n = Y_n\}$$

die Treffzeit der Markov-Ketten. Wir zeigen zunächst:  $P(T < \infty) = 1$ .

Offenbar ist  $(X_n, Y_n)_{n \in \mathbb{N}_0}$  eine Markov-Kette auf  $S^2$  mit Übergangsmatrix  $\hat{P} = (\hat{p}_{(ij)(kl)})$ , wobei  $\hat{p}_{(ij)(kl)} = p_{ik} \cdot p_{jl}$ . Weiter ist  $\hat{p}_{(ij)(kl)}^{(n)} = p_{ik}^{(n)} \cdot p_{jl}^{(n)}$  und mit Lemma 4.1: Die Kette  $(X_n, Y_n)$  ist irreduzibel und aperiodisch. Man kann nachrechnen:

$$\hat{\pi}(i, j) := \pi(i) \cdot \pi(j)$$

ist eine stationäre Verteilung für  $(X_n, Y_n)$ , also ist sie nach Satz 3.2 positiv rekurrent.

Sei  $X_0 = i$  und die Startverteilung  $\hat{\nu}$  von  $(X_n, Y_n)$  gegeben durch  $\hat{\nu}(k, l) = \delta_i(k) \cdot \pi(l)$ . Für  $b \in S$  sei

$$T_{(b,b)} := \inf\{n \in \mathbb{N} \mid (X_n, Y_n) = (b, b)\}.$$

Offenbar ist  $T \leq T_{(b,b)}$  und  $P_{\hat{\nu}}(T_{(b,b)} < \infty) = 1$ . Daraus folgt, dass  $P_{\hat{\nu}}(T < \infty) = 1$ .

(2) Betrachte  $(Z_n)_{n \in \mathbb{N}_0}$  definiert durch

$$Z_n = \begin{cases} X_n, & \text{für } n \leq T \\ Y_n, & \text{für } n > T. \end{cases}$$

Es ist  $(Z_n)$  eine Markov-Kette mit Übergangsmatrix  $P$  und  $Z_0 = i$ , denn:

Nach Satz 1.1 genügt es zu zeigen, dass

$$\forall n \in \mathbb{N}, i_k \in S : P_{\hat{\nu}}(Z_k = i_k, 0 \leq k \leq n) = \delta_i(i_0) \prod_{k=0}^{n-1} p_{i_k, i_{k+1}}$$

Es gilt

$$\begin{aligned} & P_{\hat{\nu}}(Z_k = i_k, 0 \leq k \leq n) \\ &= \sum_{r=0}^n P_{\hat{\nu}}(Z_k = i_k, 0 \leq k \leq n, T = r) \\ & \quad + P_{\hat{\nu}}(Z_k = i_k, 0 \leq k \leq n, T > n) \\ &= \sum_{r=0}^n \underbrace{P_{\hat{\nu}}(X_k = i_k, 0 \leq k \leq r, Y_k = i_k, r+1 \leq k \leq n, Y_0 \neq i_0, \dots, Y_{r-1} \neq i_{r-1}, Y_r = i_r)}_{=: \text{I}} \\ & \quad + \underbrace{P_{\hat{\nu}}(X_k = i_k, 0 \leq k \leq n, Y_0 \neq i_0, \dots, Y_n \neq i_n)}_{=: \text{II}} \end{aligned}$$

mit

$$\begin{aligned}
I &= P_{\hat{\nu}}(X_k = i_k, 0 \leq k \leq r) \cdot P_{\hat{\nu}}(Y_k = i_k, r+1 \leq k \leq n | Y_0 \neq i_0, \dots, Y_{r-1} \neq i_{r-1}, Y_r = i_r) \cdot \\
&\quad P_{\hat{\nu}}(Y_0 \neq i_0, \dots, Y_{r-1} \neq i_{r-1}, Y_r = i_r) \\
&= \delta_i(i_0) \cdot \prod_{k=0}^{r-1} p_{i_k, i_{k+1}} \cdot \prod_{k=r}^{n-1} p_{i_k, i_{k+1}} \cdot P_{\hat{\nu}}(Y_0 \neq i_0, \dots, Y_{r-1} \neq i_{r-1}, Y_r = i_r) \\
&= \delta_i(i_0) \cdot \prod_{k=0}^{n-1} p_{i_k, i_{k+1}} \cdot P_{\hat{\nu}}(Y_0 \neq i_0, \dots, Y_{r-1} \neq i_{r-1}, Y_r = i_r), \\
II &= \dots = \delta_i(i_0) \cdot \prod_{k=0}^{n-1} p_{i_k, i_{k+1}} \cdot P_{\hat{\nu}}(Y_0 \neq i_0, \dots, Y_{n-1} \neq i_{n-1}, Y_n \neq i_n)
\end{aligned}$$

Tatsächlich gilt also

$$P_{\hat{\nu}}(Z_k = i_k, 0 \leq k \leq n) = \delta_i(i_0) \cdot \prod_{k=0}^{n-1} p_{i_k, i_{k+1}}$$

(3) Es gilt nun

$$\begin{aligned}
p_{i,j}^{(n)} &= P_{\hat{\nu}}(Z_n = j) = P_{\hat{\nu}}(Z_n = j, T \leq n) + P_{\hat{\nu}}(Z_n = j, T > n) \\
\pi(j) &= P_{\hat{\nu}}(Y_n = j) = \underbrace{P_{\hat{\nu}}(Y_n = j, T \leq n)}_{=P_{\hat{\nu}}(Z_n=j, T \leq n)} + P_{\hat{\nu}}(Y_n = j, T > n) \\
\Rightarrow |p_{i,j}^{(n)} - \pi(j)| &\leq 2 \cdot P_{\hat{\nu}}(\underbrace{T > n}_{\downarrow \{T=\infty\}}) \longrightarrow 0
\end{aligned}$$

#### Satz 4.3

Seien  $i, j \in S$  Zustände sowie  $d_j$  die Periode von  $j$ . Dann gilt:

$$\lim_{n \rightarrow \infty} p_{i,j}^{(n \cdot d_j + r)} = \frac{d_j}{m_j} \sum_{k=0}^{\infty} f_{i,j}^{(k \cdot d_j + r)} \quad r = 1, \dots, d_j$$

Speziell:

- a) Ist  $j$  transient oder nullrekurrent (d.h.  $m_j = \infty$ ), so gilt  $p_{i,j}^{(n)} \longrightarrow 0$
- b) Ist  $j$  aperiodisch (d.h.  $d_j = 1$ ), so gilt  $p_{i,j}^{(n)} \longrightarrow \frac{1}{m_j} f_{i,j}^*$

## 5. Markov-Ketten und Martingale

**Erinnerung:**  $(X_n)$  heißt *Martingale*, falls

- a)  $E|X_n| < \infty$

# I. Markov-Ketten mit diskretem Zeitparameter

b)  $E[X_{n+1}|X_1, \dots, X_n] = X_n$ , bzw.

b')  $E[X_{n+1}|\mathcal{F}_n] = X_n$ , wobei  $\mathcal{F}_n := \sigma(X_1, \dots, X_n)$  die *natürliche Filtration* bezeichnet.

**Erinnerung:** Sei  $(\Omega, \mathcal{F}, P)$  W-Raum,  $X$  Zufallsvariable mit  $E|X| < \infty$ ,  $\mathcal{G} \subseteq \mathcal{F}$  Unter- $\sigma$ -Algebra.  $Z := E[X|\mathcal{G}]$  heißt bedingter Erwartungswert von  $X$  bzgl.  $\mathcal{G}$ , falls

a)  $Z$  ist  $\mathcal{G}$ -messbar

b)  $\int_A Z \cdot dP = \int_A X \cdot dP \quad \forall A \in \mathcal{G}$

Sei  $(X_n)$  eine Markov-Kette auf dem Zustandsraum  $S$  mit Übergangsmatrix  $P$  sowie  $\mathcal{F}_n := \sigma(X_1, \dots, X_n)$  die natürliche Filtration. Weiter sei  $h : S \rightarrow \mathbb{R}$  und  $P : (S \rightarrow \mathbb{R}) \rightarrow (S \rightarrow \mathbb{R})$  definiert durch

$$(Ph)(i) := \sum_{j \in S} p_{i,j} \cdot h(j) \quad \forall i \in S$$

NB: “Ph” macht Sinn im Sinne einer “Matrix·Vektor”-Multiplikation.

## Lemma 5.1

Sei  $h : S \rightarrow \mathbb{R}$  eine Funktion mit  $\|P|h\|_\infty < \infty$ . Dann gilt:

$$(Ph)(X_n) = E[h(X_{n+1})|\mathcal{F}_n]$$

## Beweis

Wir prüfen nach, dass  $(Ph)(X_n)$  ein bedingter Erwartungswert von  $h(X_{n+1})$  bzgl.  $\mathcal{F}_n$  ist.

a)  $(Ph)(X_n)$  ist  $\mathcal{F}_n$ -messbar, denn  $X_n$  ist  $\mathcal{F}_n$ -messbar.

b) Sei  $A := \{X_0 = i_0, \dots, X_n = i_n\} \in \mathcal{F}_n$ . Dann:

$$\begin{aligned} \int_A (Ph)(X_n) \cdot dP &= \int 1_A \cdot (Ph)(X_n) \cdot dP = \int 1_{\{X_0=i_0, \dots, X_n=i_n\}} (Ph)(i_n) \cdot dP \\ &= (Ph)(i_n) \cdot P(A) = \sum_{j \in S} p_{i_n,j} \cdot h(j) \cdot P(X_0 = i_0) \cdot \prod_{k=0}^{n-1} p_{i_k, i_{k+1}} \\ &= \sum_{j \in S} h(j) \cdot P(X_0 = i_0, \dots, X_n = i_n, X_{n+1} = j) = \sum_{j \in S} \int_{A \cap \{X_{n+1}=j\}} h(X_{n+1}) \cdot dP \\ &= \sum_{j \in S} \int_A 1_{\{X_{n+1}=j\}} h(X_{n+1}) \cdot dP \stackrel{LDC}{=} \int_A h(X_{n+1}) \cdot dP \end{aligned}$$

Da jedes  $A \in \mathcal{F}_n$  abzählbare Vereinigung solcher “Elementarereignisse” ist, folgt die Behauptung. ■

**Satz und Definition 5.2**

Seien  $P$  eine Übergangsmatrix auf  $S$  und  $h : S \rightarrow \mathbb{R}$  eine Funktion mit  $\|P|h|\|_\infty < \infty$ . Gilt dann  $Ph = h$ , so nennen wir  $h$  *harmonisch*. Im Fall  $Ph \geq h$  bzw.  $Ph \leq h$  heißt  $h$  *sub-* bzw. *superharmonisch*.

Ist  $(X_n)$  eine Markov-Kette mit Übergangsmatrix  $P$  und  $h$  [sub-/super-]harmonisch, so ist  $(h(X_n))$  ein  $(\mathcal{F}_n)$ -[Sub-/Super-]Martingal.

**Beweis**

Nach Lemma 5.1 gilt

$$E[h(X_{n+1})|\mathcal{F}_n] = Ph(X_n) = h(X_n) + (Ph - h)(X_n)$$

$\leadsto$  Behauptung. ■

**Bemerkung:** Ist  $h : S \rightarrow \mathbb{R}$  eine beschränkte Funktion, so wird durch

$$\begin{aligned} Z_n^h &:= h(X_n) - \sum_{k=1}^n (E[h(X_k) | \mathcal{F}_{k-1}] - h(X_{k-1})) \\ &= h(X_n) - \sum_{k=1}^n (Ph - h)(X_{k-1}) \end{aligned}$$

ein Martingal definiert, genannt Levi-Martingal zu  $(X_n)$ .

Die Markoveigenschaft lässt sich über Levi-Martingale charakterisieren:

**Satz 5.3**

Es sei  $(X_n)_{n \in \mathbb{N}_0}$  ein stochastischer Prozess mit Werten in  $S$  und natürlicher Filtration  $(\mathcal{F}_n)$ , d.h.  $\mathcal{F}_n = \sigma(X_0, \dots, X_n)$ , und  $P$  sei eine stochastische Matrix auf  $S$ . Ist dann für alle beschränkten  $h : S \rightarrow \mathbb{R}$  der Prozess

$$Z_n^h := h(X_n) - \sum_{k=1}^n (Ph - h)(X_{k-1})$$

ein  $(\mathcal{F}_n)$ -Martingal, so ist  $X_n$  eine homogene Markov-Kette mit Übergangsmatrix  $P$ .

**Beweis**

Aus  $E[Z_{n+1}^h | \mathcal{F}_n] = Z_n^h$  erhält man

$$E[h(X_{n+1}) | \mathcal{F}_n] = (Ph)(X_n)$$

bzw.

$$\int_A h(X_{n+1}) dP = \int_A (Ph)(X_n) dP \text{ für alle } A \in \mathcal{F}_n$$

## I. Markov-Ketten mit diskretem Zeitparameter

Es sei  $i_0, i_1, \dots, i_{n+1} \in S$  und  $A := \{X_0 = i_0, \dots, X_n = i_n\}$  und wir setzen  $h := 1_{\{i_{n+1}\}}$ . Die linke Seite der letzten Gleichung ergibt dann

$$\int_A h(X_{n+1}) dP = P(X_0 = i_0, \dots, X_n = i_n, X_{n+1} = i_{n+1})$$

und die rechte Seite ergibt

$$\begin{aligned} \int_A (Ph)(X_n) dP &= \int_{\{X_0=i_0, \dots, X_n=i_n\}} (Ph)(i_n) dP \\ &= \int_{\{X_0=i_0, \dots, X_n=i_n\}} p_{i_n i_{n+1}} dP \\ &= p_{i_n i_{n+1}} \cdot P(X_0 = i_0, \dots, X_n = i_n). \end{aligned}$$

Durch Teilen der rechten Wahrscheinlichkeit erhält man


$$P(X_{n+1} = i_{n+1} \mid X_0 = i_0, \dots, X_n = i_n) = p_{i_n i_{n+1}}. \quad \blacksquare$$

**Bemerkung:** Es gilt: Ist  $(X_n)_{n \in \mathbb{N}_0}$  ein nicht-negatives Supermartingal, so gibt es eine Zufallsvariable  $X_\infty$  mit

$$\lim_{n \rightarrow \infty} X_n = X_\infty \quad P - \text{f.s.}$$

### Beispiel 5.1

Jedem Feld eines schachbrettartigen  $N \times N$ -Gitters wird eine von  $L$  möglichen Farben zugewiesen. Diese Färbung wird mittels Zufallsexperimenten modifiziert: Eine Zelle wird gleichverteilt gewählt, daraufhin wird einer der vier Nachbarn (modulo  $N$ ) zufällig gewählt und dessen Farbe dem zuerst gewählten Feld zugewiesen. Offensichtlich ist dies eine Markov-Kette und die monochromen Zustände sind die absorbierenden.



Formal seien  $L, N \in \mathbb{N}$ ,  $L, N \geq 2$ .  $I := \{1, \dots, N\}^2$ ,  $S := \{1, \dots, L\}^I = \{f : I \rightarrow \{1, \dots, L\}\}$ . Sei  $(X_n)$  die Markov-Kette in  $S$ , die die Zustandsfolge angibt.

Wie verhält sich die Folge für  $n \rightarrow \infty$ ? Sei  $l \in \{1, \dots, L\}$  fest und  $Y_n$  sei die Anzahl der Felder mit Farbe  $l$  (zum Beispiel: blau) im Zustand  $X_n$ . Sei  $(A, B)$  ein Nachbarpaar im Gitter. Wäre dies die Wahl in einem Zustandsübergang, so gelte: Ist  $X_n(A) = X_n(B)$  oder  $X_n(A) \neq l, X_n(B) \neq l$ ,

so gilt auch  $Y_{n+1} = Y_n$ . Ist dagegen  $X_n(A) = l$  und  $X_n(B) \neq l$ , so ist  $Y_{n+1} = Y_n - 1$ . Ist letztlich  $X_n(A) \neq l$  und  $X_n(B) = l$ , so ist  $Y_{n+1} = Y_n + 1$ .

Die Wahrscheinlichkeit, erst  $A$ , dann  $B$  zu wählen ist gleich der Wahrscheinlichkeit, erst  $B$  und dann  $A$  zu wählen. Damit ist

$$E[Y_{n+1} \mid X_1, \dots, X_n] = Y_n.$$

Sei  $\mathcal{F}_n := \sigma(X_0, \dots, X_n)$ . Dann ist  $(Y_n)_{n \in \mathbb{N}_0}$  ein  $(\mathcal{F}_n)$ -Martingal. Nach der Bemerkung folgt:  $Y_n \rightarrow Y_\infty$  für ein  $n \rightarrow \infty$   $P$ -fast-sicher. Da  $(Y_n)$  ganzzahlig ist, ist  $Y_n(\omega)$  konstant ab einem  $n \geq n_0(\omega)$ . Als Konstanten kommen nur 0 und  $N^2$  in Frage, denn für  $k \in \{1, \dots, N^2 - 1\}$  gilt

$$\begin{aligned} P(Y_{n+j} = k \mid Y_n = \dots = Y_{n+j-1} = k) &\leq 1 - \frac{1}{N^2 4} \\ \implies P(Y_n = \dots = Y_{n+j} = k) &\leq (1 - \frac{1}{N^2 4})^j \\ \implies P(\underbrace{Y_m = k, \forall m \geq n}_{=: A_n}) &= 0 \end{aligned}$$

Es gilt  $\{\omega \in \Omega \mid \exists n \forall m \geq n : Y_m(\omega) = k\} = \bigcup_{n=0}^{\infty} A_n$ . Damit ist

$$P(\lim_{n \rightarrow \infty} Y_n = k) = P(\exists n \forall m \geq n : Y_n = k) \leq \sum_{n=0}^{\infty} P(A_n) = 0$$

und wir folgern, dass  $P(Y_\infty \in \{0, N^2\}) = 1$ .

Außerdem gilt noch, da  $Y_n$  beschränkt ist:

$$EY_\infty = \lim_{n \rightarrow \infty} EY_n = EY_0.$$

Damit ist die Wahrscheinlichkeit, dass das Feld irgendwann komplett blau ist, gleich

$$P(Y_\infty = N^2) = \frac{1}{N^2} EY_\infty = \frac{1}{N^2} EY_0 = \frac{1}{N^2} \#\{A \in I \mid X_0(A) = l\}.$$

Anwendungen dieses Modells findet man in der Physik (Vielteilchensysteme), in der Biologie (Ausbreitung von Infektionen) oder in der Finanzmathematik (Kreditrisiken).

## 6. Die starke Markov-Eigenschaft

Gegeben sei eine Markov-Kette  $(X_n)_{n \in \mathbb{N}_0}$  mit Zustandsraum  $S$  auf dem Wahrscheinlichkeitsraum  $(\Omega = S_0^{\mathbb{N}_0}, \mathcal{F} := \otimes_{n=0}^{\infty} \mathcal{P}(S), P)$ . Beachte, dass die Mengen

$$Z(i_0, i_1, \dots, i_n) := \{i_0\} \times \{i_1\} \times \dots \times \{i_n\} \times S \times S \times \dots$$

für  $n \in \mathbb{N}_0$ ,  $i_0, \dots, i_n \in S$  ein durchschnittsstabiles Erzeugendensystem für  $\mathcal{F}$  bilden. Weiter sei  $(\mathcal{F}_n)_{n \in \mathbb{N}_0}$  mit  $\mathcal{F}_n = \sigma(X_0, \dots, X_n)$  die natürliche Filtration von  $(X_n)$ .

$\tau : \Omega \rightarrow \mathbb{N}_0$  sei eine  $(\mathcal{F}_n)$ -Stoppzeit, das heißt  $\{\tau \leq n\} \in \mathcal{F}_n$  und  $P(\tau < \infty) = 1$ . Die gestoppte Markov-Kette  $X^\tau = (X_n^\tau)_{n \in \mathbb{N}_0}$  ist

$$X_n^\tau := X_{\min(\tau, n)}$$

für  $n \in \mathbb{N}_0$  und  $Y = (Y_n)_{n \in \mathbb{N}_0}$  definiert durch

$$Y_n := X_{\tau+n}$$

heißt der Post- $\tau$ -Prozess.

**Satz 6.1 (Starke Markov-Eigenschaft)**

Mit den oben eingeführten Bezeichnungen gilt:

- a)  $Y$  ist eine Markov-Kette mit Übergangsmatrix  $P$  und Startverteilung  $\nu$ , wobei  $X_\tau \sim \nu$ .
- b)  $X^\tau$  und  $Y$  sind unter  $X_\tau$  bedingt unabhängig.

**Beweis**

a.) Es gilt:

$$\begin{aligned} & P(Y_0 = i_0, \dots, Y_n = i_n, Y_{n+1} = i_{n+1}) \\ &= \sum_{k=0}^{\infty} P(\tau = k, X_k = i_0, \dots, X_{k+n+1} = i_{n+1}) \\ &= \sum_{k=0}^{\infty} P(X_{k+n+1} = i_{n+1} \mid X_k = i_0, \dots, X_{k+n} = i_n, \tau = k) \cdot P(X_k = i_0, \dots, X_{k+n} = i_n, \tau = k) \\ &= p_{i_n i_{n+1}} \sum_{k=0}^{\infty} P(X_k = i_0, \dots, X_{k+n} = i_n, \tau = k) \\ &= p_{i_n i_{n+1}} P(Y_0 = i_0, \dots, Y_n = i_n) \implies \text{Behauptung.} \end{aligned}$$

b.) Seien

$$\begin{aligned} A &:= Z(i_0, \dots, i_m) = \{i_0\} \times \dots \times \{i_m\} \times S \times S \times \dots \\ B &:= Z(j_0, \dots, j_n), \end{aligned}$$

dann gilt:

$$\begin{aligned} & P(X^\tau \in A, Y \in B, X_\tau = j) \\ &= \sum_{k=0}^{\infty} P(\tau = k, X_{0 \wedge k} = i_0, \dots, X_{m \wedge k} = i_m, X_k = j_0, \dots, X_{k+n} = j_n, X_k = j) \\ &= \sum_{k=0}^{\infty} P(X_k = j_0, \dots, X_{k+n} = j_n \mid X_{0 \wedge k} = i_0, \dots, X_{m \wedge k} = i_m, X_k = j, \tau = k) \\ &\quad \cdot P(X_{0 \wedge k} = i_0, \dots, X_{m \wedge k} = i_m, X_k = j, \tau = k) \\ &= P(X_0 = j_0, \dots, X_n = j_n \mid X_0 = j) \cdot P(X^\tau \in A, X_\tau = j) \\ &= P(Y \in B \mid X_\tau = j) \cdot P(X^\tau \in A \mid X_\tau = j) \cdot P(X_\tau = j) \end{aligned}$$

Teilen durch  $P(X_\tau = j) \implies$  Behauptung. ■